

Attention Is All You Need

Ashish Vaswani*

Google Brain

avaswani@google.com

Noam Shazeer*

Google Brain

noam@google.com

Niki Parmar*

Google Research

nikip@google.com

Jakob Uszkoreit*

Google Research

usz@google.com

Llion Jones*

Google Research

llion@google.com

Aidan N. Gomez*[†]

University of Toronto

aidan@cs.toronto.edu

Lukasz Kaiser*

Google Brain

lukaszkaizer@google.com

Illia Polosukhin*[‡]

illia.polosukhin@gmail.com

Tóm tắt nội dung

Các mô hình chuyển đổi chuỗi (sequence transduction) chủ đạo hiện nay đều dựa trên các mạng nơ-ron hồi quy (recurrent neural networks) hoặc tích chập (convolutional) phức tạp bao gồm một bộ mã hóa (encoder) và một bộ giải mã (decoder). Các mô hình có hiệu suất tốt nhất cũng kết nối bộ mã hóa và bộ giải mã thông qua một cơ chế chú ý (attention mechanism). Chúng tôi đề xuất một kiến trúc mạng đơn giản và mới mẻ, **Transformer**, hoàn toàn chỉ dựa trên các cơ chế chú ý, loại bỏ hoàn toàn sự hồi quy và tích chập. Các thử nghiệm trên hai tác vụ dịch máy (machine translation) cho thấy các mô hình này vượt trội về chất lượng, đồng thời có khả năng tính toán song song cao hơn và yêu cầu thời gian huấn luyện ít hơn đáng kể. Mô hình của chúng tôi đạt 28.4 BLEU trên tác vụ dịch tiếng Anh sang tiếng Đức WMT 2014, cải thiện hơn 2 BLEU so với các kết quả tốt nhất hiện có, bao gồm cả các mô hình tổ hợp (ensembles). Trên tác vụ dịch tiếng Anh sang tiếng Pháp WMT 2014, mô hình của chúng tôi thiết lập một điểm số BLEU tốt nhất (state-of-the-art) mới cho mô hình đơn là 41.8 sau khi huấn luyện trong 3.5 ngày trên tám GPU, chỉ bằng một phần nhỏ chi phí huấn luyện của các mô hình tốt nhất trong y văn. Chúng tôi chứng minh rằng Transformer có khả năng khái quát hóa tốt (generalizes well) sang các tác vụ khác bằng cách áp dụng nó thành công vào tác vụ phân tích cú pháp thành phần tiếng Anh (English constituency parsing) với cả dữ liệu huấn luyện lớn và hạn chế.

1 Giới thiệu (Introduction)

Các mạng nơ-ron hồi quy, đặc biệt là long short-term memory [13] và gated recurrent [7], đã được khẳng định vững chắc là các phương pháp tiên tiến nhất (state of the art) trong các bài toán lập mô hình chuỗi (sequence modeling) và chuyển đổi chuỗi như lập mô hình ngôn ngữ và dịch máy [35, 2, 5]. Nhiều nỗ lực kể từ đó đã tiếp tục đẩy lùi các giới hạn của mô hình ngôn ngữ hồi quy và kiến trúc encoder-decoder [38, 24, 15].

Các mô hình hồi quy thường tính toán phân tích theo các vị trí ký hiệu (symbol positions) của chuỗi đầu vào và đầu ra. Bằng cách căn chỉnh các vị trí với các bước trong thời gian tính toán, chúng tạo ra một chuỗi các trạng thái ẩn (hidden states) h_t , như một hàm của trạng thái ẩn trước đó h_{t-1} và đầu vào tại vị trí t . Bản chất tuần tự (sequential) vốn có này ngăn cản khả năng song song hóa (parallelization) trong các mẫu huấn luyện, điều này trở nên nghiêm trọng ở các độ dài chuỗi dài hơn, do giới hạn

bộ nhớ hạn chế việc phân lô (batching) qua các mẫu. Công trình gần đây đã đạt được những cải tiến đáng kể về hiệu quả tính toán thông qua các kỹ thuật phân tích nhân tử (factorization tricks) [21] và tính toán có điều kiện [32]. Tuy nhiên, hạn chế cơ bản của tính toán tuần tự vẫn còn đó.

Các cơ chế chú ý (attention mechanisms) đã trở thành một phần không thể thiếu trong các mô hình lập mô hình chuỗi và chuyển đổi hấp dẫn trong nhiều tác vụ khác nhau, cho phép lập mô hình các phụ thuộc (dependencies) bất kể khoảng cách của chúng trong chuỗi đầu vào hay đầu ra [2, 19]. Tuy nhiên, trong hầu hết các trường hợp [27], các cơ chế chú ý như vậy được sử dụng kết hợp với một mạng hồi quy.

Trong công trình này, chúng tôi đề xuất **Transformer**, một kiến trúc mô hình tránh xa sự hồi quy và thay vào đó hoàn toàn dựa vào cơ chế chú ý để vẽ ra các phụ thuộc toàn cục (global dependencies) giữa đầu vào và đầu ra. Transformer cho phép song song hóa nhiều hơn đáng kể và có thể đạt được kết quả state-of-the-art mới về chất lượng dịch thuật chỉ sau mười hai giờ huấn luyện trên tám GPU P100.

*Đóng góp ngang nhau. Thứ tự liệt kê là ngẫu nhiên... [CHI TIẾT FOOTNOTE TÁC GIẢ BẢO TOÀN TỪ BẢN GỐC].


[†]Công việc được thực hiện khi ở Google Brain. [‡]Công việc được thực hiện khi ở Google Research.

Hội nghị lần thứ 31 về Hệ thống Xử lý Thông tin Nơ-ron (NIPS 2017), Long Beach, CA, USA.

2 Kiến thức nền tảng (Background)

Mục tiêu giảm thiểu tính toán tuần tự cũng hình thành nền tảng của Extended Neural GPU [16], ByteNet [18] và ConvS2S [9], tất cả đều sử dụng mạng nơ-ron tích chập (convolutional neural networks) làm khối xây dựng cơ bản, tính toán các biểu diễn ẩn song song cho tất cả các vị trí đầu vào và đầu ra. Trong các mô hình này, số lượng thao tác cần thiết để liên kết các tín hiệu từ hai vị trí đầu vào hoặc đầu ra bất kỳ tăng theo khoảng cách giữa các vị trí, tuyến tính cho ConvS2S và logarit cho ByteNet. Điều này làm cho việc học các phụ thuộc giữa các vị trí xa nhau trở nên khó khăn hơn [12]. Trong Transformer, điều này được giảm xuống một số lượng thao tác không đổi, mặc dù phải trả giá bằng độ phân giải hiệu quả bị giảm do việc lấy trung bình các vị trí được đánh trọng số chú ý, một hiệu ứng mà chúng tôi khắc phục bằng Chú ý đa đầu (Multi-Head Attention) như được mô tả trong phần 3.2.

Tự chú ý (Self-attention), đôi khi được gọi là chú ý nội bộ (intra-attention), là một cơ chế chú ý liên kết các vị trí khác nhau của một chuỗi duy nhất để tính toán một biểu diễn của chuỗi đó. Tự chú ý đã được sử dụng thành công trong nhiều tác vụ... [4, 27, 28, 22].



Hình 1: Hình 1: Kiến trúc mô hình Transformer.

3 Kiến trúc mô hình (Model Architecture)

Hầu hết các mô hình chuyển đổi chuỗi nơ-ron cạnh tranh đều có cấu trúc encoder-decoder [5, 2, 35]. Ở đây, bộ mã hóa ánh xạ một chuỗi đầu vào gồm các biểu diễn ký hiệu $(x_1, \dots, x_n)$ thành một chuỗi các biểu diễn liên tục $\mathbf{z} = (z_1, \dots, z_n)$. Với $\mathbf{z}$, bộ giải mã sau đó tạo ra một chuỗi đầu ra $(y_1, \dots, y_m)$ gồm các ký hiệu tại từng phần tử một.

3.1 Các ngăn xếp Mã hóa và Giải mã (Encoder and Decoder Stacks)

Bộ mã hóa (Encoder): Bộ mã hóa bao gồm một ngăn xếp gồm $N = 6$ lớp giống hệt nhau. Mỗi lớp có hai lớp con (sub-layers). Lớp thứ nhất là cơ chế tự chú ý đa đầu (multi-head self-attention mechanism), và lớp thứ hai là

một mạng feed-forward kết nối đầy đủ theo vị trí (position-wise fully connected feed-forward network). Chúng tôi sử dụng một kết nối thẳng dư (residual connection) [11] xung quanh mỗi lớp trong hai lớp con, tiếp theo là chuẩn hóa lớp (layer normalization) [1]. Đó là, đầu ra của mỗi lớp con là $\text{LayerNorm}(x + \text{Sublayer}(x))$. Để tạo điều kiện thuận lợi cho các kết nối thẳng dư này, tất cả các lớp con trong mô hình tạo ra đầu ra có chiều $d_{\text{model}} = 512$.

Bộ giải mã (Decoder): Bộ giải mã cũng bao gồm một ngăn xếp gồm $N = 6$ lớp giống hệt nhau. Ngoài hai lớp con trong mỗi lớp của bộ mã hóa, bộ giải mã thêm một lớp con thứ ba, thực hiện chú ý đa đầu trên đầu ra của ngăn xếp mã hóa.

3.2 Chú ý (Attention)

3.2.1 Chú ý tích vô hướng theo tỷ lệ (Scaled Dot-Product Attention)

Đầu vào bao gồm các truy vấn (queries) và khóa (keys) có chiều d_k , và các giá trị (values) có chiều d_v . Chúng tôi tính toán tích vô hướng (dot products) của truy vấn với tất cả các khóa, chia mỗi kết quả cho $\sqrt{d_k}$, và áp dụng hàm softmax để thu được trọng số trên các giá trị.

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (1)$$

3.2.2 Chú ý đa đầu (Multi-Head Attention)

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O$$

where $\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V)$

Trong đó các ma trận tham số $W_i^Q \in \mathbb{R}^{d_{\text{model}} \times d_k}$, $W_i^K \in \mathbb{R}^{d_{\text{model}} \times d_k}$, $W_i^V \in \mathbb{R}^{d_{\text{model}} \times d_v}$ và $W^O \in \mathbb{R}^{hd_v \times d_{\text{model}}}$. Trong công trình này chúng tôi sử dụng $h = 8$ đầu. Chúng tôi sử dụng $d_k = d_v = d_{\text{model}}/h = 64$.

3.3 Mạng Feed-Forward theo vị trí (Position-wise Feed-Forward Networks)

$$\text{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2 \quad (2)$$

3.4 Mã hóa vị trí (Positional Encoding)

Vì mô hình của chúng tôi không chứa hồi quy và tích chập, để mô hình sử dụng được thứ tự của chuỗi, chúng tôi tiêm (inject) thông tin về vị trí:

$$PE_{(\text{pos}, 2i)} = \sin(\text{pos}/10000^{2i/d_{\text{model}}})$$
$$PE_{(\text{pos}, 2i+1)} = \cos(\text{pos}/10000^{2i/d_{\text{model}}})$$

4 Tại sao chọn Tự chú ý (Why Self-Attention)

[Phân tích so sánh Độ phức tạp, Bảng 1...]

Bảng 1: Độ dài đường dẫn tối đa, độ phức tạp mỗi lớp và số thao tác tuần tự tối thiểu cho các loại lớp khác nhau.

Loại lớp	Độ phức tạp	Thao tác tuần tự	Đường dẫn tối đa
Self-Attention	$\mathcal{O}(n^2 \cdot d)$	$\mathcal{O}(1)$	$\mathcal{O}(1)$
Recurrent	$\mathcal{O}(n \cdot d^2)$	$\mathcal{O}(n)$	$\mathcal{O}(n)$
Convolutional	$\mathcal{O}(k \cdot n \cdot d^2)$	$\mathcal{O}(1)$	$\mathcal{O}(\log_k(n))$
Self-Attention (restricted)	$\mathcal{O}(r \cdot n \cdot d)$	$\mathcal{O}(1)$	$\mathcal{O}(n/r)$

5 Huấn luyện (Training)

5.1 Lịch trình phần cứng (Hardware and Schedule)

Chúng tôi đã huấn luyện các mô hình trên một máy có 8 GPU NVIDIA P100...

5.2 Bộ tối ưu hóa (Optimizer)

Chúng tôi đã sử dụng bộ tối ưu hóa Adam [20] với $\beta_1 = 0.9$, $\beta_2 = 0.98$ và $\epsilon = 10^{-9}$. Chúng tôi thay đổi tốc độ học (learning rate) theo công thức:

$$lrate = d_{model}^{-0.5} \cdot \min(step_num^{-0.5}, step_num \cdot warmup_steps^{-1.5}) \quad (3)$$

6 Kết quả (Results)

Mô hình Transformer (big) vượt trội hơn các mô hình tốt nhất trước đây... (Bảng 2).

Bảng 2: Transformer đạt điểm BLEU tốt hơn so với các mô hình state-of-the-art trước đó.

Mô hình (Model)	BLEU	
	EN-DE	EN-FR
ByteNet [18]	23.75	
ConvS2S [9]	25.16	40.46
Transformer (base model)	27.3	38.1
Transformer (big)	28.4	41.8

7 Kết luận (Conclusion)

Trong công trình này, chúng tôi đã trình bày Transformer, mô hình chuyển đổi chuỗi đầu tiên hoàn toàn dựa trên sự chú ý... Code của chúng tôi hiện có tại <https://github.com/tensorflow/tensor2tensor>.

Tài liệu tham khảo (References)

- [1] Jimmy Lei Ba, Jamie Ryan Kiros, and Geoffrey E Hinton. Layer normalization. *arXiv preprint arXiv:1607.06450*, 2016.
[Bảo toàn bộ nguyên văn danh sách 40 References bằng tiếng Anh theo chuẩn mực học thuật quốc tế]